

Soluciones: Actividades de Análisis y Visualización de Datos - Módulo 1

Este documento contiene la resolución detallada de los ejercicios prácticos propuestos para el Módulo 1, utilizando Python (Pandas, Matplotlib y Seaborn) para el análisis y la generación de visualizaciones.

1. Análisis de Canales de Marketing

Enunciado: Crea un gráfico que compare el número de leads generados a través de 4 canales distintos: 'SEO', 'PPC', 'Social Media' y 'Email'.


Solución:

Utilizamos un gráfico de barras para comparar categorías discretas de forma clara.

```
import seaborn as sns
import matplotlib.pyplot as plt

channels = ['SEO', 'PPC', 'Social Media', 'Email']
leads = [1250, 980, 750, 1100]

sns.barplot(x=channels, y=leads, palette="viridis")
plt.title('Leads Generados por Canal')
plt.show()
```



2. Tráfico Web Semanal

Enunciado: Visualiza la tendencia de visitas diarias a un sitio web durante una semana completa. ¿Qué día se observa el mayor pico?


Solución:

Para visualizar tendencias temporales, el gráfico de líneas es el más adecuado.

```
import matplotlib.pyplot as plt

days = ['Lunes', 'Martes', 'Miércoles', 'Jueves', 'Viernes', 'Sábado', 'Domingo']
visits = [1200, 1350, 1100, 1450, 1900, 800, 700]

plt.plot(days, visits, marker='o', linestyle='-', color='b')
plt.title('Tráfico Web Diario')
plt.xlabel('Día')
plt.ylabel('Visitas')
plt.grid(True)
plt.show()
```



Análisis: Observando el gráfico, se detecta que el **Viernes** es el día con el mayor pico de visitas (1900 visitas), seguido de un descenso pronunciado durante el fin de semana.

3. Calidad en Manufactura

Enunciado: En una línea de producción de piezas metálicas, se mide el grosor de 150 unidades. Utiliza un boxplot para determinar si hay piezas defectuosas (outliers).


Solución:

El boxplot (diagrama de caja y bigotes) permite identificar visualmente los valores atípicos que se alejan del rango intercuartílico.

```
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt

# Datos simulados con 150 piezas y algunos outliers
data = np.concatenate([np.random.normal(5, 0.05, 145), [5.3, 4.7, 5.4, 4.75, 5.25]])

sns.boxplot(y=data, color="salmon")
plt.title('Detección de Outliers en Grosor')
plt.show()
```



Resultado: En el gráfico se observan puntos individuales por encima y por debajo de los "bigotes". Estos puntos representan las **piezas defectuosas (outliers)** cuyo grosor no cumple con los estándares de la mayoría de la producción.

4. Optimización de Dataset IoT

Enunciado: Tienes un dataset con 500,000 registros de temperatura (float64) y estado del sensor (bool). Analiza el ahorro de memoria al convertir la temperatura a float32.

Solución:

Cálculo técnico:

- **float64:** Utiliza 8 bytes (64 bits) por registro.
 - Memoria: $500,000 \times 8 \text{ bytes} = 4,000,000 \text{ bytes} \approx 4 \text{ MB}$.
- **float32:** Utiliza 4 bytes (32 bits) por registro.
 - Memoria: $500,000 \times 4 \text{ bytes} = 2,000,000 \text{ bytes} \approx 2 \text{ MB}$.

Ahorro de memoria: El ahorro es de **2,000,000 bytes (50%)**. En datasets masivos de IoT, este tipo de optimización es crítica para reducir el consumo de RAM y almacenamiento sin perder una precisión significativa en las mediciones de temperatura.

5. Educación vs Salario


Enunciado: Investiga la relación entre los "Años de Estudio" y el "Salario Mensual". Representa la correlación mediante un scatter plot con línea de tendencia.

Solución:

Un gráfico de dispersión con regresión lineal permite visualizar la fuerza y dirección de la relación entre ambas variables.

```
import seaborn as sns
import matplotlib.pyplot as plt

# df contiene columnas 'Años_Estudio' y 'Salario'
sns.regplot(data=df, x='Años_Estudio', y='Salario', line_kws={'color':'red'})
plt.title('Educación vs Salario')
plt.show()
```



Interpretación: Existe una **correlación positiva fuerte**: a medida que aumentan los años de estudio, el salario mensual tiende a incrementarse, como muestra la línea de tendencia ascendente.

6. Control de Calidad Alimentaria

Enunciado: Un lote de leche tiene mediciones de pH. Implementa el método IQR para filtrar mediciones erróneas que podrían indicar fallos en los sensores.

Solución:

El método del Rango Intercuartílico (IQR) es un estándar robusto para limpieza de datos.

```
# Ejemplo de implementación
Q1 = df['pH'].quantile(0.25)
Q3 = df['pH'].quantile(0.75)
IQR = Q3 - Q1

limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Filtrado
datos_limpios = df[(df['pH'] >= limite_inferior) & (df['pH'] <= limite_superior)]
```

Este método elimina los valores extremos que suelen ser errores de lectura o fallos técnicos, asegurando que el análisis de calidad se base en datos reales del producto.

7. Rendimiento de Exámenes


Enunciado: Compara la distribución de notas de dos grupos de alumnos (Grupo A y Grupo B) utilizando gráficos KDE superpuestos.

Solución:

Los gráficos de Estimación de Densidad de Kernel (KDE) permiten comparar distribuciones continuas sin el ruido de las barras de un histograma.

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.kdeplot(grupo_a, fill=True, label='Grupo A')
sns.kdeplot(grupo_b, fill=True, label='Grupo B')
plt.title('Distribución de Notas')
plt.legend()
plt.show()
```



Comparación: El **Grupo A** muestra una distribución más concentrada alrededor de una media más alta (notablemente mejor rendimiento), mientras que el **Grupo B** tiene una mayor dispersión, lo que indica una mayor heterogeneidad en las notas.

8. Variables Meteorológicas


Enunciado: Crea un mapa de calor que muestre la correlación entre: Temperatura, Humedad, Velocidad del Viento, Presión Atmosférica y Radiación Solar.

Solución:

El Heatmap de la matriz de correlación de Pearson es la herramienta estándar para identificar relaciones entre múltiples variables numéricas simultáneamente.

```
import seaborn as sns
import matplotlib.pyplot as plt

# df_meteo es el DataFrame con las variables meteorológicas
corr = df_meteo.corr()
sns.heatmap(corr, annot=True, cmap='coolwarm')
plt.title('Matriz de Correlación Meteorológica')
plt.show()
```



9. Precios Inmobiliarios Sesgados

Enunciado: Calcula media y mediana de los precios de una calle donde 5 casas valen 200k y una mansión vale 5M. Justifica cuál usarías para una tasación justa.

Solución:

Cálculos:

- Datos: [200, 200, 200, 200, 200, 5000] (en miles)
- **Media:** $\$(5 \times 200 + 5000) / 6 = 6000 / 6 = 1,000,000\$$ (1M).
- **Mediana:** El valor central de la lista ordenada es 200,000.

Justificación: Para una tasación justa de una casa "normal" en esa calle, se debe usar la **MEDIANA**. La media está fuertemente sesgada por el outlier (la mansión), dando una cifra que no representa la realidad de la mayoría de las viviendas. La mediana es robusta ante valores extremos y refleja mejor el valor típico de la zona.

10. Dashboard de Ventas Regional

Enunciado: Diseña un dashboard con dos paneles:

1. Gráfico de barras de ventas por región.
2. Histograma de la cantidad de artículos comprados por cliente.

Solución:

Agrupamos las visualizaciones en una sola figura para facilitar la toma de decisiones ejecutiva.

```
import matplotlib.pyplot as plt
import seaborn as sns

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 5))

# Panel 1: Ventas por Región
sns.barplot(x=regiones, y=ventas, ax=ax1)

# Panel 2: Histograma de Artículos
sns.histplot(compras_clientes, bins=15, kde=True, ax=ax2)

plt.show()
```

