

Introducción al Desarrollo Ágil en Inteligencia Artificial con Scrum

El desarrollo de sistemas de Inteligencia Artificial (IA) y Aprendizaje Automático (Machine Learning - ML) difiere notablemente de la ingeniería de software tradicional. La IA no es puramente determinista: no basta con escribir código siguiendo unas reglas fijas, sino que dependemos de la calidad de los datos, la experimentación continua con algoritmos y el comportamiento probabilístico de los modelos.

Para gestionar esta incertidumbre de forma eficiente sin perder el foco en el valor de negocio, la metodología ágil **Scrum** se ha convertido en el estándar de la industria. A lo largo de esta lectura, exploraremos los fundamentos de Scrum aplicados a un proyecto real: **el desarrollo de un sistema inteligente de detección de fraude en transacciones financieras**.

Contenidos del Módulo

- 1. El Cambio de Paradigma: Agile frente al Enfoque Tradicional (Cascada)
 - ¿Por qué la Cascada falla en proyectos de Inteligencia Artificial?
 - La Alternativa Ágil: El Manifiesto Ágil adaptado a la IA
 - [2. Los Roles en un Equipo Scrum para Inteligencia Artificial](#2-los-roles-en-un-equipo-scrum-para-inteligencia-artificial)
 - A. El Product Owner (PO)
 - B. El Scrum Master (SM)
 - C. El Equipo de Desarrollo (Development Team)
 - 3. Las Ceremonias de Scrum: El Control Empírico del Proceso
 - 4. Caso Práctico Desarrollado: Un Sprint en Acción
 - Fase 1: Planificación (Día 1 - Sprint Planning)
 - Fase 2: Ejecución y Sincronización (Días 2 al 9)
 - Fase 3: Inspección y Adaptación (Día 10 - Sprint Review y Retrospective)
 - 5. Glosario de Conceptos Tecnológicos (IA y Machine Learning)
 - Conclusión
-

1. El Cambio de Paradigma: Agile frente al Enfoque Tradicional (Cascada)

En la ingeniería de software tradicional, el modelo en **Cascada (Waterfall)** divide el proyecto en fases secuenciales estrictas: *Requisitos* $\rightarrow$ *Diseño* $\rightarrow$ *Implementación* $\rightarrow$ *Pruebas* $\rightarrow$ *Despliegue*.

Enfoque Tradicional (Cascada):

[Requisitos] $\rightarrow$ [Diseño] $\rightarrow$ [Desarrollo] $\rightarrow$ [Pruebas] $\rightarrow$ [Despliegue]

(Si el modelo no converge al final, el proyecto fracasa tras meses de trabajo)

Enfoque Ágil (Scrum):

[Sprint 1: Modelo Baseline] $\rightarrow$ [Sprint 2: Feature Engineering] $\rightarrow$ [Sprint

3: Optimización]
(Iterativo, adaptativo, mitiga riesgos de forma temprana)

¿Por qué la Cascada falla en proyectos de Inteligencia Artificial?

1. **La incertidumbre de los datos:** En Cascada, definimos todos los requisitos al inicio. Sin embargo, a mitad del proyecto podemos descubrir que los datos históricos de transacciones están muy sesgados, incompletos o que carecemos de etiquetas de fraude fiables. Corregir esto en cascada requiere reiniciar todo el ciclo, con un coste económico y temporal altísimo.
2. **El riesgo de la no-convergencia matemática:** En IA, no sabemos con certeza si un modelo alcanzará la precisión requerida por el negocio hasta que experimentamos con él. En Cascada, el modelo se evalúa al final del ciclo. Si tras seis meses de trabajo descubrimos que el algoritmo no supera el 60% de precisión (lo que lo hace inútil en producción), el proyecto habrá fracasado por completo.

La Alternativa Ágil: El Manifiesto Ágil adaptado a la IA


El enfoque ágil asume que **el cambio es inevitable y que la experimentación es parte del desarrollo**. En lugar de planificar el modelo definitivo desde el primer día, Scrum propone entregar valor de manera incremental en ciclos cortos llamados **Sprints** (habitualmente de 2 semanas):

- **Sprint 1 (Modelo Baseline):** Creamos un clasificador básico (por ejemplo, una regresión logística sencilla) con una muestra de datos limpios. Esto nos da una línea base de rendimiento.
- **Sprint 2 (Feature Engineering):** Añadimos nuevas variables al modelo (como la ubicación geográfica o la frecuencia de transacciones del usuario) y probamos un algoritmo más complejo (como un *Random Forest*).
- **Sprint 3 (Optimización y Despliegue):** Ajustamos los hiperparámetros del modelo seleccionado e iniciamos la integración en la API de pagos.

Este flujo iterativo permite obtener retroalimentación constante de los datos y del negocio, reduciendo drásticamente el riesgo técnico y de mercado.

2. Los Roles en un Equipo Scrum para Inteligencia Artificial

Un equipo Scrum es multidisciplinar y autoorganizado. En el contexto de la Inteligencia Artificial, los tres roles tradicionales de Scrum se adaptan de forma específica para dar soporte a la naturaleza científica del desarrollo:



impedimentos de infra)

ML/Data Engineers...)

A. El Product Owner (PO)

Es la voz del cliente y del negocio. Se encarga de maximizar el valor del producto gestionando y priorizando el **Product Backlog** (la lista de tareas pendientes).

- **Su papel en IA:** El PO traduce los problemas de negocio a objetivos medibles por el equipo técnico. No necesita conocer el funcionamiento interno de una red neuronal, pero debe saber definir qué nivel de error es aceptable para el negocio.
- *Ejemplo:* El PO define la siguiente prioridad: *"Necesitamos reducir el coste de las transacciones fraudulentas no detectadas en un 15%, manteniendo la tasa de falsos positivos (usuarios bloqueados por error) por debajo del 2%"*.

B. El Scrum Master (SM)

Es el facilitador del equipo, el guardián del proceso Scrum y quien elimina los obstáculos (impedimentos) que frenan el avance del equipo.

- **Su papel en IA:** Los equipos de IA a menudo sufren bloqueos externos muy específicos: retrasos en la concesión de accesos a bases de datos protegidas, falta de recursos de computación (GPU bloqueadas en la nube) o aprobaciones regulatorias de privacidad de datos (RGPD). El Scrum Master actúa como un escudo protector y negociador para resolver estos impedimentos con rapidez.

C. El Equipo de Desarrollo (Development Team)

Es el grupo técnico encargado de convertir los requisitos del backlog en incrementos de producto potencialmente entregables en cada Sprint. En IA, este equipo es altamente multidisciplinar:

- **Ingenieros de Datos (Data Engineers):** Construyen las canalizaciones (*pipelines*) de datos robustas para asegurar que el modelo reciba información limpia y en tiempo real.
- **Científicos de Datos (Data Scientists):** Diseñan los experimentos, entrenan los modelos predictivos y evalúan métricas matemáticas como la precisión, el *recall* y el F1-Score.
- **Ingenieros de ML (Machine Learning Engineers) / Ingenieros de Software:** Empaquetan el modelo entrenado, lo optimizan y lo integran en los sistemas de producción para que pueda ser consumido por otras aplicaciones.

3. Las Ceremonias de Scrum: El Control Empírico del Proceso

El control de procesos en Scrum se apoya en tres pilares empíricos: **transparencia, inspección y adaptación**. Esto se instrumenta a través de cuatro ceremonias estructuradas:

Ceremonia	Duración habitual (Sprint de 2 semanas)	Propósito en Proyectos de IA	Ejemplo Práctico (Detector de Fraude)
Sprint Planning	2 - 4 horas	Definir el objetivo del Sprint (<i>Sprint Goal</i>) y seleccionar las tareas del backlog necesarias para lograrlo.	El equipo se compromete al siguiente objetivo: <i>"Establecer el modelo de detección baseline y conectar la pipeline de datos históricos de transacciones"</i> . Se seleccionan y estiman tareas como "Extracción de datos históricos" y "Entrenamiento de regresión logística".
Daily Scrum	15 minutos (diarios)	Reunión diaria para sincronizar el trabajo, revisar el avance hacia el objetivo del Sprint y detectar bloqueos inmediatos.	Un Data Scientist comparte: <i>"Ayer intenté entrenar el modelo pero obtuve sobreajuste (overfitting). Hoy probaré técnicas de regularización. Necesito que el Data Engineer me confirme si los datos de entrenamiento están balanceados"</i> .
Sprint Review	1 - 2 horas	Demostrar el incremento de valor al Product Owner y a los interesados (<i>stakeholders</i>) para obtener feedback real e inmediato.	En lugar de mostrar diapositivas teóricas sobre matemáticas de optimización, el equipo presenta un <i>Notebook</i> interactivo o una interfaz básica donde se introducen transacciones simuladas y el modelo responde en tiempo real clasificándolas y justificando el nivel de confianza de la predicción.
Sprint Retrospective	1 - 1.5 horas	Evaluar el proceso de trabajo del equipo e identificar mejoras concretas para implantar en el siguiente Sprint.	El equipo detecta un problema: <i>"Pasamos demasiado tiempo limpiando datos de forma manual durante el Sprint"</i> . Como acción de mejora para el próximo ciclo, acuerdan: <i>"Automatizar un pipeline básico de preprocesamiento utilizando herramientas de calidad de datos"</i> .

4. Caso Práctico Desarrollado: Un Sprint en Acción

Para consolidar el aprendizaje, analizaremos cómo se desarrolla de principio a fin un Sprint de 2 semanas en el equipo encargado del **Detector de Fraude**.

Fase 1: Planificación (Día 1 - Sprint Planning)

El **Product Owner** establece el objetivo del Sprint:

"Aumentar la detección de transacciones fraudulentas de alto valor a través de un nuevo modelo predictivo de Machine Learning y desplegarlo en un entorno de pruebas accesible vía API".

El **Equipo de Desarrollo** analiza el Backlog y divide el trabajo en tareas técnicas de 2 a 5 días de duración. Estiman el esfuerzo y acuerdan el siguiente **Sprint Backlog**:

Sprint Backlog - Detector de Fraude (Sprint 4):

Por Hacer (To Do)	En Proceso (Doing)	Hecho (Done)
[] [IA-404] QA: Pruebas de estrés de carga a la API	[] [IA-402] DS: Entrenamiento del modelo XGBoost	
	[] [IA-401] DE: Pipeline ETL de datos históricos	
	[] [IA-403] MLE: Creación de API FastAPI / Contenedor	

(Abreviaturas: DE = Data Engineer; DS = Data Scientist; MLE = ML Engineer; QA = Calidad)

Fase 2: Ejecución y Sincronización (Días 2 al 9)

El equipo trabaja de forma paralela. Durante las **Daily Scrum**, coordinan sus avances cotidianos.

- **Día 3 (Daily Scrum):**

- *Data Engineer*: "He completado la extracción del pipeline ETL. Los datos ya están listos en formato estructurado en el servidor".
- *Data Scientist*: "Perfecto. Hoy mismo empiezo a preparar los datos para entrenar el clasificador XGBoost".

- **Día 5 (Daily Scrum - Bloqueo / Impedimento):**

- *Data Scientist*: "Tengo un problema crítico. Las transacciones fraudulentas reales representan menos del 0.2% del volumen total de datos. El modelo XGBoost está sesgándose y predice que todo es transaccionalidad normal, lo que resulta en un Recall del 0%".
- *Scrum Master*: "Es un problema clásico de datos desbalanceados. ¿Qué necesitamos para solucionarlo?".
- *Data Scientist*: "Debemos aplicar una técnica de balanceo como sobremuestreo sintético (SMOTE). Esto me llevará un día y medio más de experimentación".
- *Scrum Master*: "De acuerdo, voy a ajustar las prioridades del Sprint con el Product Owner para retrasar temporalmente la prueba de estrés de carga y darte el espacio para balancear el modelo. Es clave que resolvamos la calidad predictiva primero".

- **Día 8 (Superación del bloqueo):**

- La científica de datos completa el balanceo. El modelo XGBoost converge y alcanza una métrica estable: **Precisión del 88% y Recall del 84% (F1-Score del 86%)**, superando ampliamente la línea base.
- El ML Engineer toma el modelo serializado (.pk1) y lo integra en un microservicio utilizando FastAPI montado en un contenedor Docker.

Fase 3: Inspección y Adaptación (Día 10 - Sprint Review y Retrospective)

La Sprint Review (10:00 AM)

El equipo se reúne con el **Product Owner** y directores del banco.

1. **Demostración Práctica:** En lugar de mostrar código, el equipo simula transacciones financieras a través de un panel sencillo en la web.
2. **Ejemplo en Vivo:** Introducen una transacción legítima de \$50 y el modelo devuelve una alerta negativa en 35ms. Posteriormente, simulan una transacción de \$12,000 en un horario inusual (3:00 AM) y desde un dispositivo móvil no registrado. El sistema enciende una alerta roja instantáneamente con un nivel de confianza del 94.5%.
3. **Métricas y Negocio:** El Product Owner revisa las métricas de precisión y recall y aprueba el incremento de producto: *"Esto cumple de sobra el objetivo del Sprint. Procedamos a preparar el despliegue controlado en producción"*.

La Sprint Retrospective (15:00 PM)

El equipo reflexiona sobre su forma de trabajar:

- **¿Qué salió bien?** La colaboración rápida entre el Data Engineer y la Data Scientist para atajar el problema de desbalanceo de datos evitó el estancamiento del Sprint.
- **¿Qué salió mal o se puede mejorar?** El ML Engineer tuvo problemas para instalar ciertas librerías en el entorno en la nube porque los permisos del servidor estaban restringidos por ciberseguridad, lo que retrasó las pruebas 24 horas.
- **Acción de Mejora (Acuerdo de Equipo):**

"Para el próximo Sprint, el Scrum Master coordinará previamente con el equipo de ciberseguridad la pre-aprobación del perfil Docker de despliegue antes de comenzar la integración."

5. Glosario de Conceptos Tecnológicos (IA y Machine Learning)

Para que los perfiles de gestión (como el Product Owner o el Scrum Master) y de desarrollo colaboren eficazmente, es vital compartir un vocabulario común. A continuación, se definen los conceptos de IA clave utilizados en este texto:

Modelo Baseline (Modelo de Línea Base)

- **Definición:** Es el modelo más sencillo y rápido de implementar que se utiliza como punto de partida o "plantilla" de comparación.
- **Propósito en Scrum:** Permite validar de forma inmediata que el flujo de datos funciona de extremo a extremo (*end-to-end*). Cualquier modelo complejo desarrollado en Sprints posteriores deberá

demostrar que es significativamente mejor que este baseline para justificar su coste computacional y de desarrollo.

Feature Engineering (Ingeniería de Características)

- **Definición:** El proceso de transformar datos brutos en variables (características) que faciliten a los algoritmos de Machine Learning la detección de patrones.
- **Propósito in Scrum:** Es una de las tareas más comunes e iterativas en el Backlog. En nuestro detector de fraude, convertir una columna con una "fecha y hora" en variables numéricas como "hora del día" o "días desde la última transacción" facilita enormemente el entrenamiento.

Overfitting (Sobreajuste)

- **Definición:** Error que ocurre cuando un modelo de IA aprende tan detalladamente los datos de entrenamiento (incluyendo el ruido o las anomalías) que pierde la capacidad de generalizar ante datos nuevos.
- **Propósito en Scrum:** Es un "bloqueo" técnico muy habitual que suele surgir en las *Dailies*. Cuando se detecta, el equipo debe pivotar en sus tareas para aplicar técnicas de simplificación (regularización, reducción de variables o recolección de más datos).

Data Pipeline (Canalización de Datos)

- **Definición:** Conjunto de procesos e infraestructura automatizada que extrae datos de diferentes fuentes, los transforma (limpieza, formato) y los carga en el sistema de destino (el modelo de IA).
- **Propósito en Scrum:** Es el pilar fundamental que construyen los *Data Engineers*. Un modelo sin una pipeline estable no puede operar en producción de manera continua.

Dataset Balanceado

- **Definición:** Un conjunto de datos de entrenamiento donde las categorías a predecir están representadas de forma equitativa.
- **Propósito en Scrum:** En la detección de fraudes, el fraude real representa menos del 1% de las transacciones (datos muy desbalanceados). Si el modelo entrena con esto sin corregirlo, aprenderá la regla simple de "todo es legítimo" y tendrá un 99% de acierto aparente, pero será inútil. Balancear el dataset es una prioridad crítica que el equipo planifica en el Sprint.

Métricas de Evaluación

Son los indicadores matemáticos que miden el rendimiento del modelo:

- **Precisión (Precision):** De todos los casos que el modelo clasificó como fraude, ¿cuántos lo eran realmente? (Evita falsas alarmas que bloqueen cuentas a usuarios legítimos).
- **Sensibilidad (Recall):** De todos los fraudes reales que ocurrieron, ¿cuántos fue capaz de detectar el modelo? (Evita pérdidas económicas por fraudes no detectados).
- **F1-Score:** La media armónica entre la Precisión y el Recall. Proporciona una métrica única y robusta para evaluar modelos cuando los datos están muy desbalanceados.

Conclusión

Scrum no consiste en eliminar la rigurosidad científica de la Inteligencia Artificial, sino en **enmarcar la investigación y la experimentación dentro de ciclos iterativos alineados con el valor de negocio**. Al estructurar el trabajo en Sprints, definir claramente los roles y evaluar el progreso mediante ceremonias constantes, los equipos logran reducir la incertidumbre inherente de la IA, asegurando que los modelos desarrollados respondan verdaderamente a las necesidades del mundo real de manera ágil y sostenible.